

```

1 C:\Users\Minh\anaconda3\envs\my-rdkit-env\python.exe D:\Minh\Books\
  Research\Accelerated-Paper\Github\scripts\prepare_dataset.py
2 Python: 63230 molecules.
3 Excel: 63230 molecules.
4 Python: 63230 molecules.
5 Excel: 62861 molecules.
6 Identical: 62861 molecules.
7 Python only: 369 molecules.
8 Python-only molecules: {'OCCC1NCNCN1', 'O=C[C@H](O)c1cccc1', 'CSc1ccc(O)
  cc1', 'COC1CCC(C)CC1', 'NNCC1CCCCC1', 'CC(=O)C1CCC(C)CC1', 'NN1CCOC1=O', '
  C#CC#Cc1cccc1', 'NC(=O)Cn1ccsc1=O', 'NC(=S)NC1CCCCC1', 'N#CNC1CCCCC1', '
  CC(=O)CC1CCCCC1', 'C=C[C@H](O)C1CCCCC1', 'CC1CCC(C=O)CC1', 'C=C=CC1CCCCC1
  ', 'OCC1CCCCC1', 'CN1CCN(C(N)=O)C1=O', 'COC(=O)C1CCCCC1', 'C=CCn1cccc1', '
  C#CC1CCNCC1', 'CC(=O)C1CCNCC1', 'C#C/C=C/n1cccc1', 'CC(C)C1CCC(N)CC1', '
  CCCCC1CCCCC1', 'C=CC(=C)c1cccc1', 'O=CCC1CCCCC1', 'CCn1cccn1=O', 'C#
  CCOC1CCCCC1', 'C#C/C=C/C1CCCCC1', 'CCC(=O)C1CCCCC1', 'O=C(O)Nc1cccc1', '
  FC(F)Oc1ccncc1', 'CN(C)Cc1ccncc1', 'CN1Cc2cccn2C1', 'C=C1CCC(=C)CC1', 'O=
  NOC1CCCCC1', 'C=C(C)CC1CCCCC1', 'CNc1ccc(N)cc1', 'CCOC1CCC(O)CC1', 'C=C[C@
  H](C)N1CCCC1', 'CNCCn1cccc1', 'NOC1CCCCC1', 'CC(C)CC1CCCCC1', '
  CSCSc1cccc1', 'C[C@H](CO)C1CCCCC1', 'NCCSc1cccc1', 'c1coen1', 'C#C[C@H](
  O)C1CCCCC1', 'CS(=O)(=O)C1CCNCC1', 'C1CCNCC1', 'C[S@](=O)c1ccc(N)cc1', '
  NCCC1CCCCC1', 'COCc1ccncc1', 'C#CCC1CCCCC1', 'CC[C@H](N)c1cccc1', '
  COCCc1cccc1', 'NC(=O)OC1CCCCC1', 'CCCN1ccoc1=O', 'CCCN1cccc1', 'C[C@H](
  S)C1CCCCC1', 'CSCC1CCC(C)CC1', 'O=c1ccocc1', 'O=CC#Cc1cccc1', 'CCCN1cccc1
  ', 'OCCSC1CCCCC1', 'C=C(C)Cn1cccc1', 'COCCn1cccc1', 'C[C@H](CN)N1CCCC1', '
  C=CCOc1ccncc1', 'CCOCc1ccncc1', 'C[C@H](N)CC1CCCCC1', 'CC1CCC([C@H](C)O)
  CC1', 'N#Cc1ccc(C=O)cc1', 'C[S@@](=O)c1ccc(N)cc1', 'O=C(O)C1CCC(F)CC1', '
  COc1ccc(CN)cc1', 'CNC(=O)C1CCCCC1', 'C/C=N/C1CCCCC1', 'C=CCC1CCC(C)CC1', '
  NCC1CCC(O)CC1', 'NNC(=O)C1CCCCC1', 'O=C(O)N1CCCC1', 'CC(C)SC1CCCCC1', 'NC[
  C@H](O)c1cccc1', 'O=CCOC1CCCCC1', 'CCC(=O)n1cccc1', 'OC(O)C1CCCCC1', '
  c1ccc2ccccc2c1', 'CCCNc1cccc1', 'c1ccccoccc1', 'ONCc1cccc1', 'ONC1CCCCC1
  ', 'NN1CCc2ccccc21', 'CC1CCC(C(N)=O)CC1', 'O=CNC1CCCCC1', 'NC(=O)c1ccc(O)
  cc1', 'CCSCc1cccc1', 'CCCN1CCC(=O)CC1', 'O=C1OCCN1CCO', 'CC(=O)N1CCC(=O)
  CC1', 'CNCCC1CCNCC1', 'CCOC1CCNCC1', 'OCCNc1ccncc1', 'CN1CCCCC1=N', '
  CC1CCC(OO)CC1', 'CCSC1CCCCC1', 'CCC#CC1CCCCC1', 'C=C1C[C@H]1C1CCCCC1', 'N
  #CC1CCC(CN)CC1', 'CCCC(=O)n1cccc1', 'CSCCC1CCCCC1', 'CS(=O)(=O)C1CCCCC1
  ', 'NC(N)=NC1CCCCC1', 'CC1CCC(CN)CC1', 'C[C@H](O)Cc1cccc1', 'c1cnenc1', '
  C[C@H](C#N)n1cccc1', 'CCC1CCC(C=O)CC1', 'CN(C)CCn1cccc1', 'N=C1CC1', 'C[C@
  H](CO)N1CCCC1', 'O=C1CCCCC1', 'CCOC(=O)n1cccc1', 'O=CN1CCCCC1=O', 'CC(C)
  C1CCCCC1', 'C[C@H](S)c1cccc1', 'C=CC1CCC(O)CC1', 'Cc1ccncc1', 'CC(C)n1ccc
  (=O)cc1', 'FC(Cl)(Cl)c1cccc1', 'NCCC1CCNCC1', 'OOC1CCCCC1', 'O=COc1CCCCC1
  ', 'N=C(N)SC1CCCCC1', 'CCCC1CCNCC1', 'Cn1ccc(=NN)cc1', 'C1CNC2NCCCC2C1', '
  OCCn1ccncc1', 'OCc1ccncc1', 'CCn1ccc(=O)cc1', 'CC(C)OC1CCNCC1', 'CS(=O)(=O)
  n1cccc1', 'N[C@@H](CF)c1cccc1', 'NS(=O)(=O)c1ccncc1', 'CCN(C)c1cccc1', '
  CCCN1CCCCC1=O', 'CCc1ccc(N)cc1', 'Cn1ccc(=O)o1', 'C1CCCCC1', 'Cn1ccn(CO)c1
  =O', 'COC1CCCCC1', 'CNCCc1ccc(C)cc1', 'C[C@]1(C2CCCCC2)CO1', 'C1CCC(C2CNC2)
  CC1', 'CCNCCn1cccc1', 'O=C(O)c1cccc1', 'CCNCCc1ccncc1', 'C=C(C)c1cccc1
  ', 'CC(C)Cn1cccc1', 'Cn1cnc(=O)n(C)c1=O', 'C/N=c1\|n(C)ccn1N', 'CNC1CCC(C)
  CC1', 'COC(=O)n1ccoc1=O', 'C#CCOc1ccncc1', 'CCN1CCCC1', 'CCCN1CCNC1', 'CC
  (C)SC1CCNCC1', 'CCN(C)c1ccncc1', 'Cc1ccc(NN)cc1', 'C[C@H](O)Cc1ccncc1', '
  CSCOC1CCCCC1', 'C[C@H](O)C1CCNCC1', 'O=[N+](O-)]C1CCCCC1', 'C=CCSc1cccc1

```

```

8 ', 'CCCc1ccc(C)cc1', 'COCc1ccc(N)cc1', 'C=CCCC1CCCCC1', 'CCCC1CCCCC1', '
C1CCn2nnnc2C1', 'O=[N+](O)CC1CCCCC1', 'NCCNC1CCCCC1', 'CCCNc1ccncc1', '
N#Cc1ccc(C#N)cc1', 'OCCCN1cccc1', 'CC[C@H](O)C1CCNCC1', 'CN(C)CC1CCCCC1
', 'CCS(=O)(=O)N1CCCC1', 'CCOC1CCCCC1', 'O=C(O)Cn1ccsc1=O', 'NCCc1ccc(N)
cc1', 'CNC1CCC(CO)CC1', 'C[C@H](C=O)N1CCCC1', 'OCCc1ccc(O)cc1', 'CNC(=O)
n1cccn1', 'COC(=N)c1ccccc1', 'O=C1CCC1=O', 'COC1CCCCC1', 'NC(=S)Cc1ccccc1
', 'CC(C)(O)C1CCCCC1', 'c1cnccn1', 'CCCCc1ccncc1', 'CCc1ccc(CC)cc1', 'C=
CCN1CCCCC1=O', 'CCSCC1CCCCC1', 'CCCOC1CCCCC1', 'CC(=O)c1ccc(O)cc1', 'CC[C@
H](O)c1ccccc1', 'C/C=C/Cc1ccccc1', 'C=CCC1CCCCC1', 'CO[C@H](C)C1CCCCC1', '
O=C1CCCCN1CO', 'NCCCN1cccc1', 'c1ccoc1', 'O=C(OO)c1ccccc1', 'O=S(=O)(O)
c1ccccc1', 'N#Cc1ccc(O)cc1', 'CCc1ncccn1', 'FC(F)CC1CCNCC1', 'C1CCC(NC2CC2
)CC1', 'COC(=O)c1ccncc1', 'COC(=O)n1cccc1', 'CCc1ccncc1', 'CC(=O)C1CCCCC1
', 'CN(C)N1CCCC1', 'CCNCc1ccccc1', 'C1CCC(N2CCC2)CC1', 'C=COC1CCCCC1', '
OCCc1ccccc1', 'C/C=C/CN1CCCC1', 'CC(C)CCn1cccc1', 'CN1CCc2cnncc21', 'C#
CCn1cccc1', 'NCc1ccccc1', 'NCc1ccncc1', 'NCCN1CCCCC1=O', 'NN1CCCCC1=O', '
NC(=S)c1ccncc1', 'C=C[C@H](C)C1CCCCC1', 'CCOc1ccncc1', 'CSCC1CCCCC1', '
NNCCc1ccccc1', 'OCC1CCCCC1', 'COCOC1CCCCC1', 'O=C(NO)C1CCCCC1', 'CC(F)(F)
c1ccncc1', 'NC1CCCCC1', 'C[C@H](N)c1ccccc1', 'CCC1CCCCC1', 'C[S@@](=O)
CC1CCCCC1', 'N#C/C=C/C1CCCCC1', 'C[C@H](C=O)C1CCCCC1', 'CNCC1CCC(N)CC1', '
CC(=O)Oc1ccncc1', 'C1CNOC1', 'FCCSC1CCCCC1', 'N[C@H](CF)c1ccccc1', 'O=C(O)
Cn1cccc1', 'c1ccc([C@H]2CO2)cc1', 'O=CC1CCC(C=O)CC1', 'OCCOc1ccncc1', '
C1Cn2nnnc2CN1', 'C#CC1CCCCC1', 'CO[C@H](C)C1CCNCC1', 'COc1ccc(C#N)cc1', '
CSCCc1ccncc1', 'OC[C@H](O)c1ccncc1', 'CN1CCN(C)C1=N', 'C#CC(=C)C1CCCCC1
', 'CCCc1ncccn1', 'CC[S@](=O)C1CCCCC1', 'OCC1CCC(O)CC1', 'C[C@H](O)c1ccc(O
)cc1', 'NCCc1ccccc1', 'C1CCN(C[C@H]2CO2)C1', 'OCN1CCCC1', 'C[S@](=O)
CC1CCCCC1', 'CN1CCc2ccccc21', 'O=C=NCC1CCCCC1', 'C1CCNNC1', 'CC(C)N1CCCC1
', 'O=C1CCCCN1O', 'OC[C@H](O)c1ccccc1', 'CC1CCC(ON)CC1', 'COc1ccccc1=O', '
CC[C@H](C)C1CCCCC1', 'N[C@@H]1C[C@H]1c1ccccc1', 'Cn1cc2ccccc2c1', 'CC(=O)
n1cccc1', 'CN1CCc2cnncc21', 'CCOC1CCC(N)CC1', 'Cn1cnc2ccccc21', 'NS(=O)(=O)
c1ccccc1', 'COc1ncc(C=O)cn1', 'O=Nc1ccncc1', 'COCn1cccc1', 'C=CC(=O)
c1ccccc1', 'O=C(CF)c1ccccc1', 'C[C@H](C#N)C1CCCCC1', 'CNCCC1CCCCC1', 'N#
CCCN1CCCC1', 'CO/C=C/C1CCCCC1', 'CNN1CCCC1', 'C=CCOC1CCCCC1', 'C[C@H](O)
c1ccccc1', 'CN(C)C(=O)N1CCCC1', 'O=CN1CCCC1', 'CCN(O)c1ccccc1', 'C#CC(=O)
C1CCCCC1', 'CN1CCC(=N)CC1', 'CC(C)(N)C1CCCCC1', 'CONCC1CCCCC1', 'C/C=C/C/
c1ccccc1', 'NN1CCCC1', 'CN(O)c1ccccc1', 'C=CC1CCCCC1', 'COc1ccc(=O)cc1', '
N=C1SCCN1CC(=O)O', 'C[C@H](N)c1ccc(F)cc1', 'NCC1CCC(N)CC1', 'O=S(=O)(O)
c1ccncc1', 'C[C@H](O)Cn1cccc1', 'C=CCn1ccc(=O)cc1', 'C1CCC(C2CC2)CC1', 'N#
CC#CC1CCCCC1', 'Oc1cnccn1', 'O=C/C=C/C1CCCCC1', 'N=C=NC1CCCCC1', 'C=
CCNC1CCCCC1', 'CCC1CCC(C)CC1', 'COc1ccncc1', 'Cn1ccn(C)c1=NN', '
CN1Cc2cnncc2C1', 'OCCCN1cccc1', 'CCNC1CCC(N)CC1', 'CC(=O)OC1CCCCC1', 'C=C(C)
C1CCC(C)CC1', 'O=C1NCCCN1O', 'C=CCN1cccc1', 'C#CCCN1cccc1', 'N#
CCOC1CCCCC1', 'CS(=O)(=O)c1ncccn1', 'CN(C)c1ccc(N)cc1', 'C#COC1CCCCC1', 'C
[C@H](NN)c1ccccc1', 'ON=C1CCCCC1', 'CN1CCC(=O)N1C', 'COc1ccc(O)cc1', 'CC[
S@@](=O)c1ccccc1', 'N#C[C@H](N)C1CCCCC1', 'CC(C)c1ncccn1', 'S=C(S)
NC1CCCCC1', 'CNCC1CCCCC1', 'CC(=O)n1ccoc1=O', 'NCCCC1CCNCC1', 'O=CC1CCCCC1
', 'O=C1CCC(=O)C1=O', 'NC(=O)Cc1ccccc1', 'CC(C)(O)c1ccncc1', 'CC(C)=
Cc1ccncc1', 'CC(C)C(=O)n1cccc1', 'CN[C@H](C)c1ccccc1', 'C1=C(n2cccc2)CCC1
', 'N#CCCN1cccc1', 'C[C@H](N)c1ccc(F)cc1', 'CC(=O)N1CCNC1', 'CNCc1ccncc1
', 'c1cnn2nnnc2c1', 'CN[C@H](C)C1CCNCC1', 'CCNC(=O)n1cccn1'}

```

9 Excel only: 0 molecules.

10 Excel-only molecules: set()

```
11  
12 Process finished with exit code 0  
13
```